Shiny y Power BI en la analítica básica y el *reporting* de datos: órdenes de compra pública de la región Puno

Mary Luz Nina Palacios

Universidad Nacional del Altiplano, Escuela de Posgrado. Maestría, curso Business Intelligence and Data Analytics. Docente: Fred Torres Cruz

Actividad Semana 2: Herramientas de analítica y *reporting*. Puno, octubre de 2026

Resumen

El presente informe compara Shiny y Power BI a partir de un caso real: las 5 925 órdenes de compra que las entidades públicas de la región Puno emitieron en los Catálogos Electrónicos de Perú Compras entre enero de 2025 y septiembre de 2026, por un total de S/ 85,19 millones. Con el mismo archivo de datos se construyó un módulo de análisis exploratorio en cada herramienta, con seis secciones equivalentes, y se comprobó que ambos producen exactamente las mismas cifras. Posteriormente, las herramientas se calificaron en doce criterios con una escala de 1 a 5 cuyos niveles están definidos de antemano, de modo que cada puntaje responde a algo observable durante el desarrollo. Shiny obtuvo 53 de 60 puntos y Power BI 47. La diferencia proviene de la analítica básica (24 frente a 18), donde R aporta histogramas, densidades y mapas con límites distritales; en el *reporting* ambas sumaron 29 puntos, aunque por razones distintas. Power BI ofrece interacción sin necesidad de programar y una menor curva de aprendizaje, mientras que Shiny permite un diseño libre y una publicación abierta sin costo. Los resultados no señalan una herramienta superior, sino dos herramientas complementarias cuya elección depende del perfil de los usuarios del reporte.

Palabras clave: inteligencia de negocios, análisis exploratorio de datos, tableros, Shiny, Power BI, compras públicas.

1. Introducción

Disponer de datos no garantiza, por sí solo, mejores decisiones. Su valor depende de que se conviertan en información comprensible y oportuna para quien debe decidir, y esa es precisamente la tarea de la inteligencia de negocios (Watson y Wixom, 2007; Chen et al., 2012). En la práctica, este trabajo comprende dos momentos. Primero se exploran los datos para entender cómo se comportan, detectar asimetrías o valores atípicos y formular buenas preguntas (Behrens, 1997). Luego se comunican los resultados en reportes o tableros que otras personas consultan de manera autónoma (Yigitbasioglu y Velcu, 2012; Sarikaya et al., 2019). La herramienta que se use en cada momento influye en lo que se puede analizar, en su costo y en la facilidad para mantener el trabajo.

Shiny y Power BI representan dos maneras distintas de resolver ese problema. Shiny es

un paquete de R con el que se construyen aplicaciones web interactivas escribiendo código, y se usa cada vez más para poner análisis estadísticos al alcance de usuarios que no programan (Jia et al., 2022). Power BI es la plataforma de inteligencia de negocios de Microsoft, pensada para preparar datos, modelarlos y publicar reportes desde una interfaz visual (Becker y Gould, 2019). Ambas permiten explorar datos y construir tableros, pero parten de lógicas distintas: la primera se basa en el código y la segunda en una interfaz de arrastrar y soltar.

Para que la comparación tuviera validez práctica se descartó un conjunto de datos de ejemplo y se trabajó con información real, reciente y de la región: las compras que municipalidades, el Gobierno Regional, hospitales, universidades y otras entidades de Puno hicieron a través de los Catálogos Electrónicos de Perú Compras. Estos datos abiertos tienen valor propio, porque permiten conocer en qué se gasta el presupuesto público, a qué proveedores se adquiere y cómo cambió el gasto de un año a otro (Janssen et al., 2012). De hecho, los registros de órdenes y contratos públicos ya se han usado para construir indicadores que alertan sobre riesgos en las compras del Estado (Fazekas y Kocsis, 2020). Así, cada herramienta se puso a prueba con preguntas de negocio y no con ejercicios de ejemplo.

El objetivo del trabajo es comparar ambas herramientas como medios de analítica básica y de *reporting*, desarrollando en cada una un módulo de análisis exploratorio sobre los mismos datos y calificándolas con criterios explícitos. En las secciones siguientes se describen los datos, se presentan los dos módulos sección por sección, se resumen los hallazgos, se explica cómo se asignó cada puntaje y, al final, se discuten los resultados.

2. Datos y preparación

Los datos provienen del conjunto *Órdenes de compra realizadas a través de los Catálogos Electrónicos*, que Perú Compras publica mes a mes en la Plataforma Nacional de Datos Abiertos (Central de Compras Públicas Perú Compras, 2026). Se descargaron los 21 archivos mensuales de enero de 2025 a septiembre de 2026. Cada archivo trae las órdenes de todo el país con la entidad compradora, el proveedor, el rubro o acuerdo marco, el tipo de procedimiento, el estado de la orden y el monto.

La fuente no indica la región de la entidad, así que se obtuvo del padrón reducido del RUC de la SUNAT (Superintendencia Nacional de Aduanas y de Administración Tributaria, 2026): a cada entidad se le asignó el ubigeo de su domicilio fiscal y se conservaron solo las del departamento de Puno (código 21). El mismo padrón permitió saber dónde tiene su domicilio cada empresa proveedora y, con ello, qué parte del gasto se destina a empresas de la región. Para el mapa se usaron los límites distritales del INEI. Toda esta preparación se hizo una sola vez, en Python, y ambas herramientas partieron del mismo archivo, lo que asegura que cualquier diferencia entre ellas venga de la herramienta y no de los datos.

El archivo final tiene 5 929 órdenes y 25 variables. Antes de analizarlo se revisó su calidad (Tabla 1). No hubo órdenes duplicadas, valores faltantes en las variables clave ni montos iguales

o menores a cero. Cuatro órdenes estaban resueltas o anuladas, es decir, no llegaron a ejecutarse, y se excluyen por defecto; por eso el análisis trabaja con 5 925 órdenes.

Tabla 1: Revisión de la calidad de los datos

Verificación	Resultado
Órdenes en el archivo	5 929
Órdenes duplicadas	0
Valores faltantes en variables clave	0
Montos iguales o menores a cero	0
Órdenes resueltas o anuladas (excluidas por defecto)	4
Proveedores sin domicilio fiscal publicado en la SUNAT	126

3. Los dos módulos de reporte

3.1 Módulo en Shiny

La aplicación está en un solo archivo, `app.R`, de unas 1 390 líneas. Usa `bslib` para el diseño, `plotly` para los gráficos, `leaflet` y `sf` para el mapa (Pebesma, 2018) y `DT` para las tablas. A la izquierda hay un panel de filtros (periodo, sector, provincia, rubro y estado) y en la parte superior, seis pestañas: Resumen, Proveedores, Entidades, Mapa distrital, Exploración y Datos. Los filtros se aplican con un botón, para que la aplicación no recalcule todo cada vez que se marca una opción, y otro botón los devuelve a su estado inicial. Cada tarjeta de indicador muestra la variación frente a 2025 y, al pasar el cursor, explica en lenguaje sencillo qué significa la cifra. La aplicación está publicada en https://mlnp.shinyapps.io/compras-puno/ y su código en https://github.com/mlnp-dev/compras-puno-shiny.

3.2 Módulo en Power BI

En Power BI se cargó el mismo archivo y se armó un modelo con dos tablas relacionadas, una de órdenes y otra de distritos con sus coordenadas, además de una tabla pequeña para elegir la métrica de los gráficos. Los cálculos están en 54 medidas DAX: indicadores, variaciones frente al año anterior, concentración, Pareto, estadísticos descriptivos y textos de ayuda. El reporte tiene las mismas seis secciones, con un menú lateral, filtros desplegables en cada página, un selector que cambia todos los gráficos entre monto, órdenes o empresas, una ventana emergente con la tendencia mensual y un botón para limpiar los filtros. Se guardó en formato de proyecto (PBIP), que conserva el modelo y las páginas como archivos de texto. Ambos módulos llevan arriba el mismo membrete institucional. El reporte se publicó en el servicio de Power BI con una cuenta institucional y la opción de publicación en la web, de modo que puede consultarse sin iniciar sesión en https://app.powerbi.com/view?r=eyJrIjoiMmJlMGJlMjQtZmU5My00YzU3LWEwZGYtMjdlNGJiZDMzNDMwIiwidCI6ImM0YTY2YzM0LTJiYjctNDUxZi04YmUxLWIyYzI2YTQzMDE1OCIsImMiOjR9; el proyecto completo

está en https://github.com/mlnp-dev/compras-puno-powerbi.

4. Comparación sección por sección

Las Figuras 1 a 6 muestran, para cada sección, la pantalla de Shiny arriba y la de Power BI abajo, con los mismos datos y sin filtros. Verlas juntas permite notar dónde coinciden y dónde cada herramienta resolvió la misma pregunta de otra manera.

Resumen. Ambas pantallas presentan los mismos cuatro indicadores con su variación frente a 2025 (Figura 1). Shiny añade una comparación acumulada de 2026 contra 2025 y anotaciones sobre el propio gráfico, como el pico de agosto o la caída de enero, que coincide con el inicio del año fiscal. Power BI resuelve lo mismo con menos elementos, pero con su selector de métrica basta un clic para que todas las figuras pasen de soles a número de órdenes o de empresas.

Proveedores. Aquí se mide qué tan concentradas están las ventas (Figura 2). En Shiny la curva de Pareto se obtuvo ordenando y acumulando en dos líneas de R. En Power BI el mismo cálculo exigió una medida con una tabla virtual, aunque el resultado se lee de forma muy directa en la tarjeta *152 de 712 empresas hacen el 80 % del monto*.

Entidades. Ambas herramientas muestran quién compra y en qué sector (Figura 3). En Power BI, al hacer clic en una barra se filtra toda la página sin necesidad de programación; en Shiny ese comportamiento tendría que programarse.

Mapa. Es la sección donde más se notan las diferencias (Figura 4). Shiny dibuja los límites reales de los 109 distritos con un color según el monto y, al hacer clic en uno, muestra quién compra y en qué. Power BI ubica una burbuja por distrito sobre Azure Maps: la presentación es cuidada y el mapa base es de buena calidad, pero no muestra los límites distritales y el visual depende de que el administrador de la organización lo tenga habilitado. Además, el mapa de Power BI tardó varios segundos en dibujarse cada vez que se abría la página. La solución de Shiny es la misma que se ha usado en tableros de vigilancia de salud pública que combinan mapas y filtros (Lu et al., 2026).

Exploración. Es la sección más propia del análisis exploratorio (Figura 5). Shiny ofrece un histograma del monto en escala logarítmica, curvas de densidad por sector, un mapa de calor por día de la semana y la tabla de valores atípicos. Power BI no tiene histograma ni gráfico de densidad nativos, así que los montos se agruparon en cinco rangos y la media, la mediana, la desviación estándar, los cuartiles y el coeficiente de variación se calcularon con medidas DAX. El resultado es correcto y fácil de leer, pero obtenerlo requirió una solución alternativa.

Datos. Ambas herramientas permiten revisar las órdenes una por una (Figura 6). Shiny trae un buscador y un botón que descarga en CSV solo lo filtrado; Power BI permite exportar desde el menú del propio visual.

5. Lo que muestran los datos

Antes de comparar las herramientas es necesario verificar que ambas produzcan los mismos resultados. Las medidas de Power BI se consultaron directamente en su motor de cálculo y se cotejaron con los valores de la aplicación Shiny. Coincidieron en todos los indicadores (Tabla 2), de modo que las diferencias que se discuten después son de forma y de proceso, no de resultado.

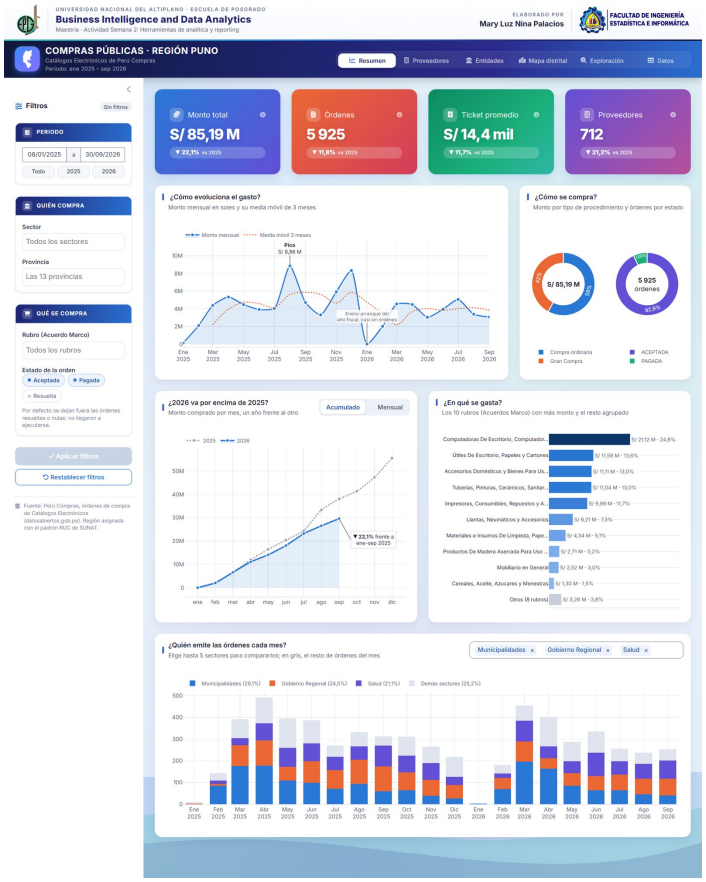
Tabla 2: Indicadores calculados en ambas herramientas

Indicador	**Shiny**	**Power BI**
Monto total	S/ 85,19 millones	S/ 85,19 millones
Órdenes	5 925	5 925
Ticket promedio	S/ 14 377	S/ 14 377
Mediana del monto por orden	S/ 3 370	S/ 3 370
Empresas proveedoras	712	712
Variación del monto, enero a septiembre de 2026 frente a 2025	−22,1 %	−22,1 %
Variación del número de órdenes en el mismo periodo	−11,8 %	−11,8 %
Monto que va a empresas de Puno	12,5 %	12,5 %
Empresas que concentran el 80 % del monto	152	152

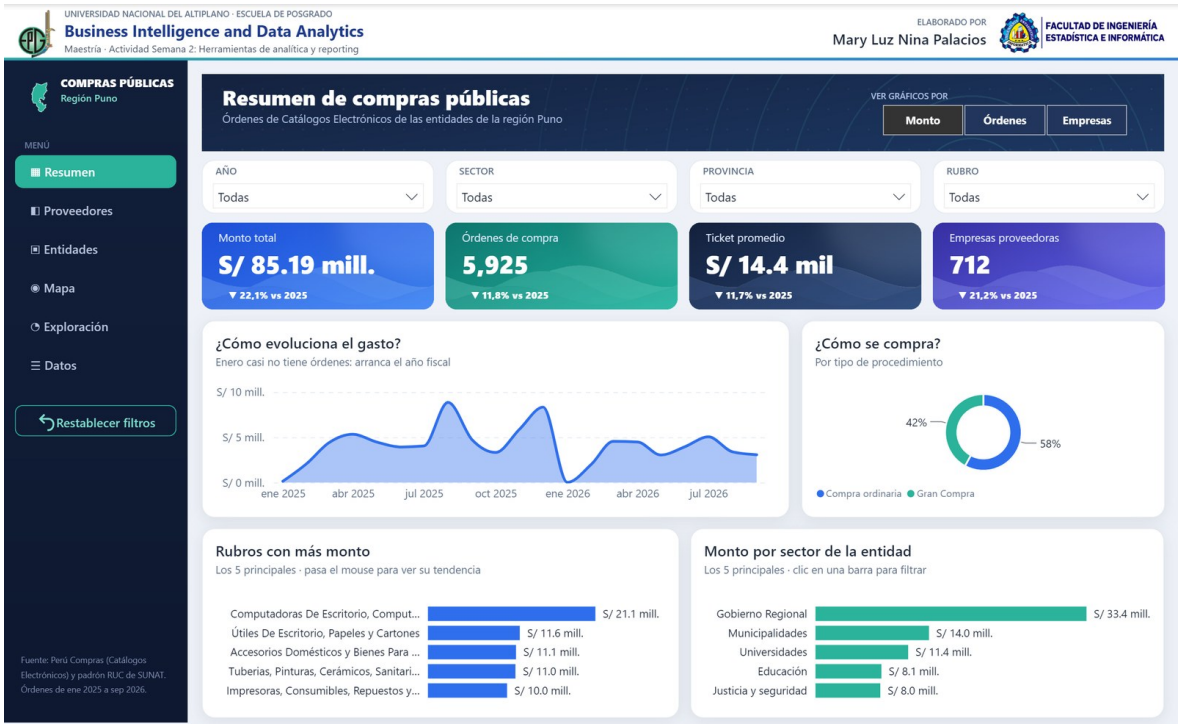
El primer resultado relevante es la reducción de las compras en 2026. Entre enero y septiembre el monto fue 22,1 % menor que en los mismos meses de 2025 (S/ 29,60 millones frente a S/ 38,02 millones), con 11,8 % menos órdenes y 21,2 % menos empresas proveedoras. Además, el gasto se concentra en pocas entidades: el Gobierno Regional es el sector que más compra (S/ 33,4 millones, 39 % del total) y una sola entidad, el Gobierno Regional Puno, explica el 36,1 % del monto. Por rubros dominan las computadoras de escritorio y portátiles, con S/ 21,1 millones (24,8 %), seguidas de los útiles de escritorio, los accesorios domésticos y las tuberías y pinturas.

En cuanto a los proveedores, las empresas con domicilio en Puno reciben solo el 12,5 % del monto, mientras que las de Lima y Callao concentran el 42 %. Asimismo, 152 de las 712 empresas, el 21,3 %, acumulan el 80 % del monto, un reparto muy cercano a la regla de Pareto. En el territorio ocurre algo parecido: el distrito de Puno concentra el 71 % del gasto (S/ 60,6 millones), 6,6 veces el monto de Juliaca, que ocupa el segundo lugar.

Los montos son muy asimétricos. La media (S/ 14 377) es 4,3 veces la mediana (S/ 3 370) y el coeficiente de variación llega a 502 %. Casi la mitad de las órdenes (46 %) está entre S/ 1 mil

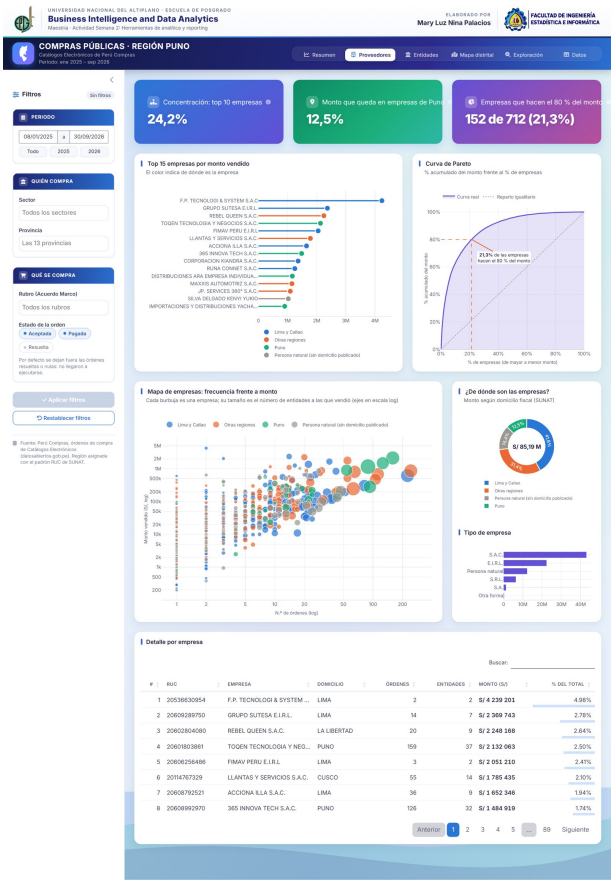


(a) Shiny, pestaña Resumen.

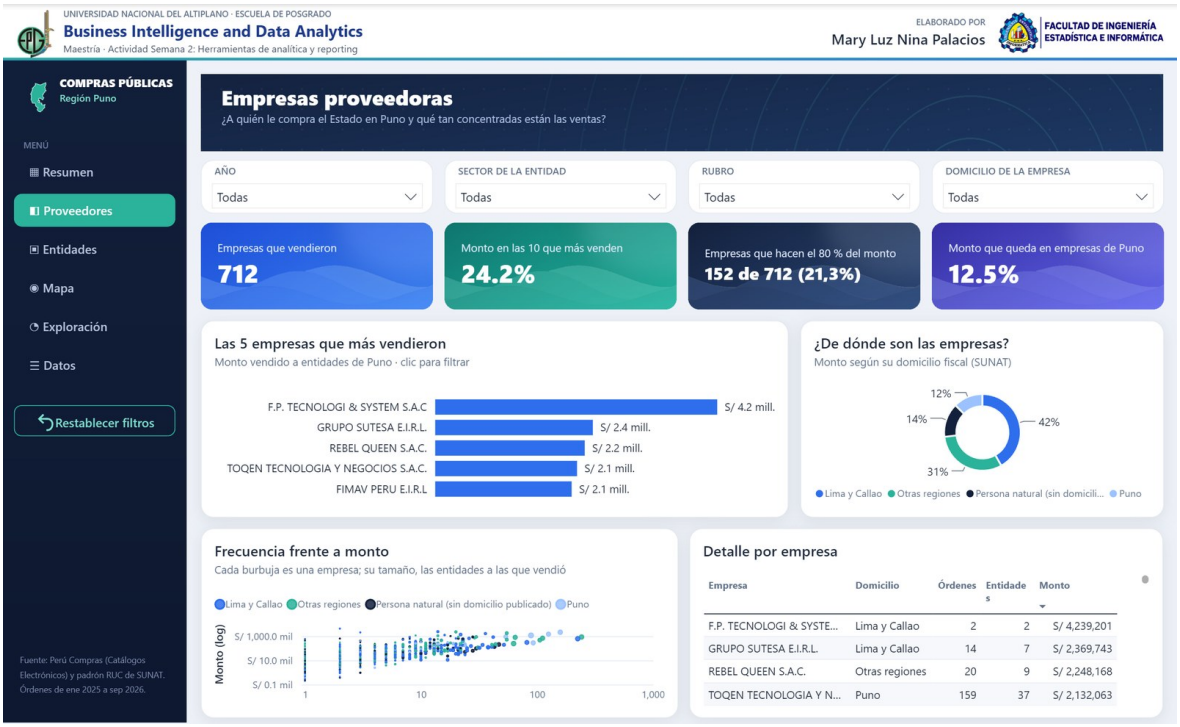


(b) Power BI, página Resumen.

Figura 1: Sección Resumen: indicadores con su variación frente a 2025, evolución mensual del gasto, rubros y sectores.



(a) Shiny, pestaña Proveedores.

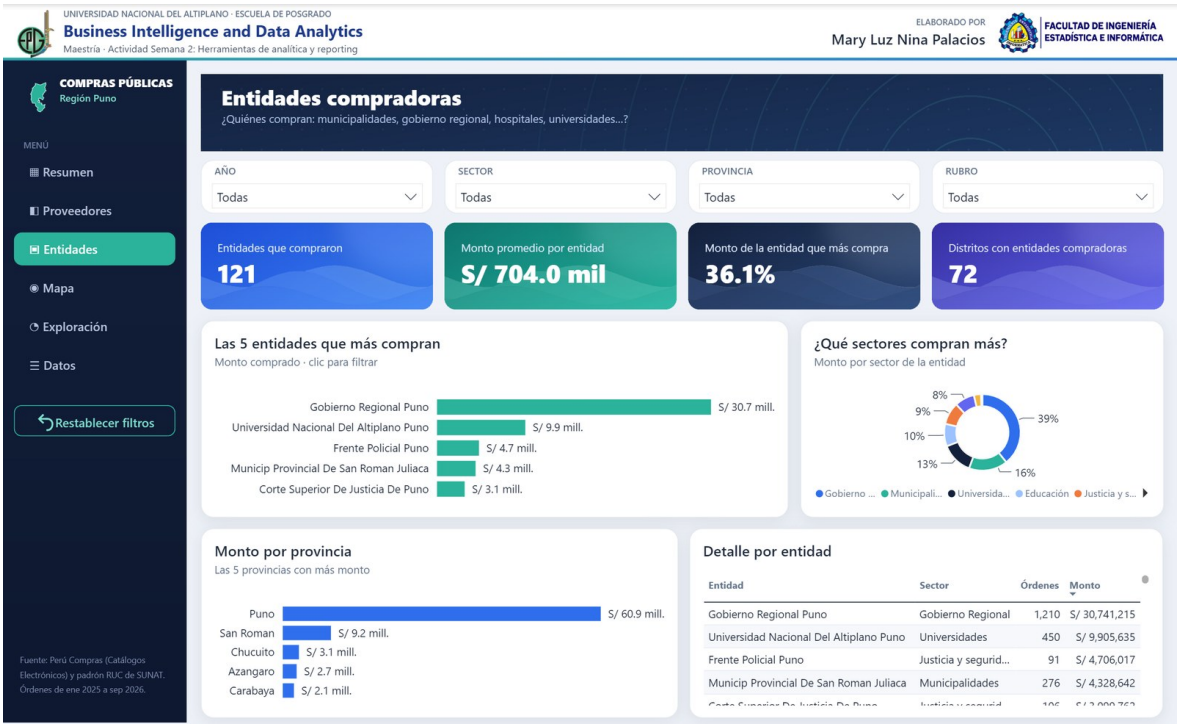


(b) Power BI, página Proveedores.

Figura 2: Sección Proveedores: concentración de las ventas, origen de las empresas y relación entre número de órdenes y monto.

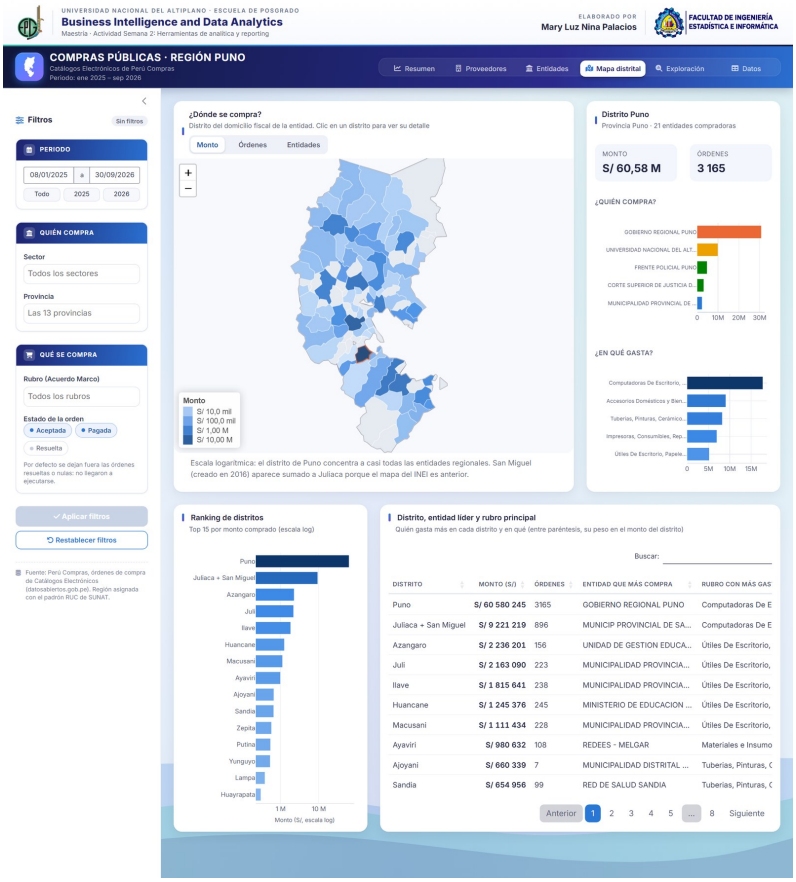


(a) Shiny, pestaña Entidades.

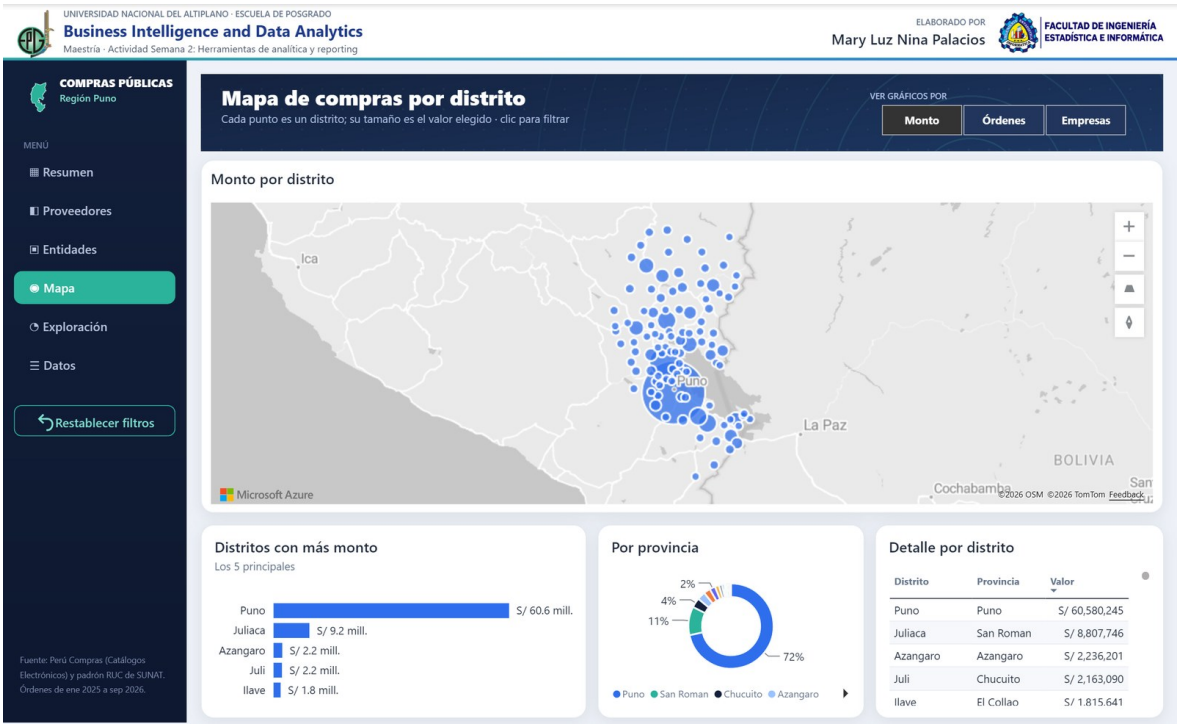


(b) Power BI, página Entidades.

Figura 3: Sección Entidades: entidades que más compran, sectores y provincias.



(a) Shiny, mapa con los límites de los distritos (`leaflet` y `sf`).

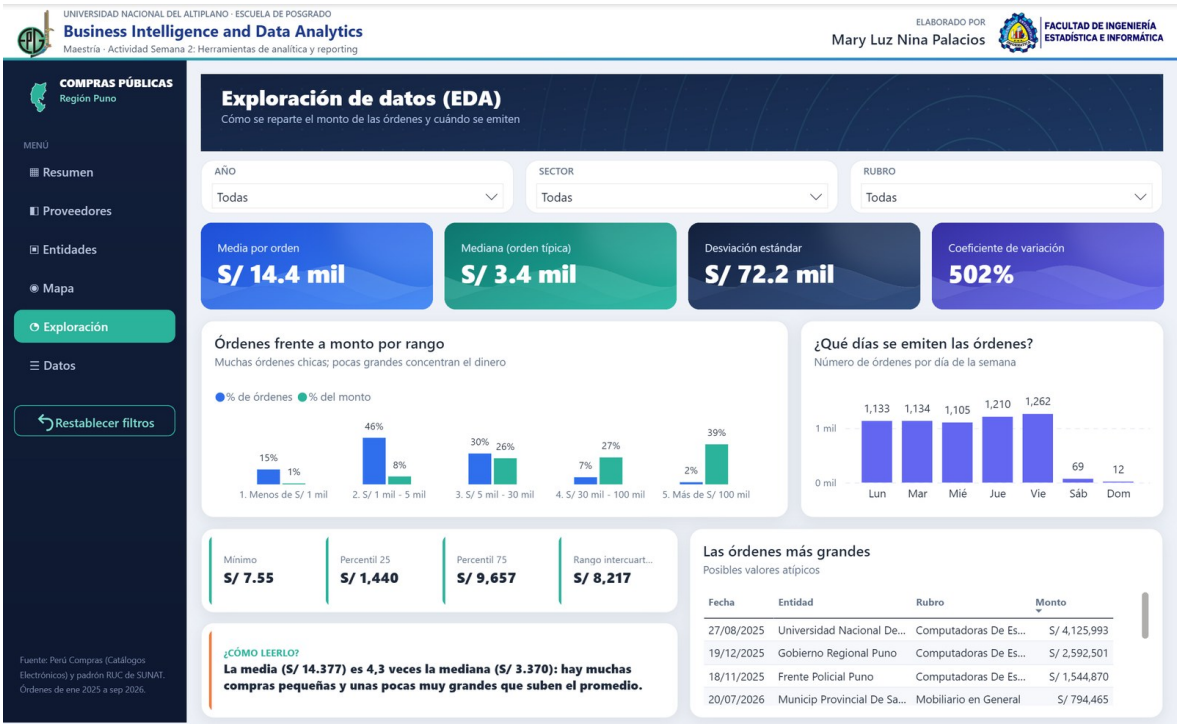


(b) Power BI, burbujas por distrito sobre Azure Maps.

Figura 4: Sección Mapa: en ambas herramientas el distrito de Puno concentra el 71 % del monto.

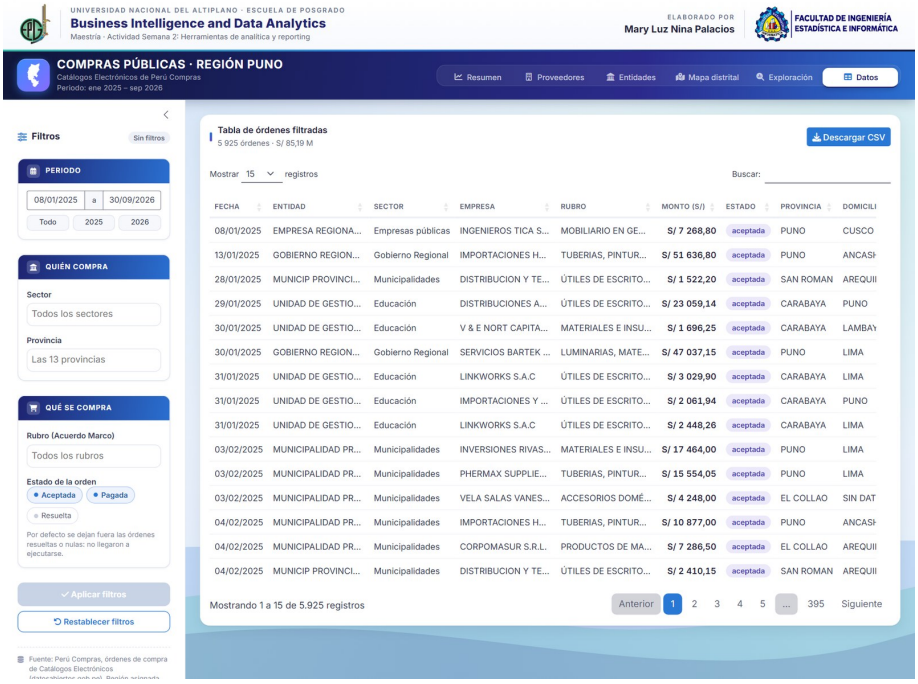


(a) Shiny, pestaña Exploración.

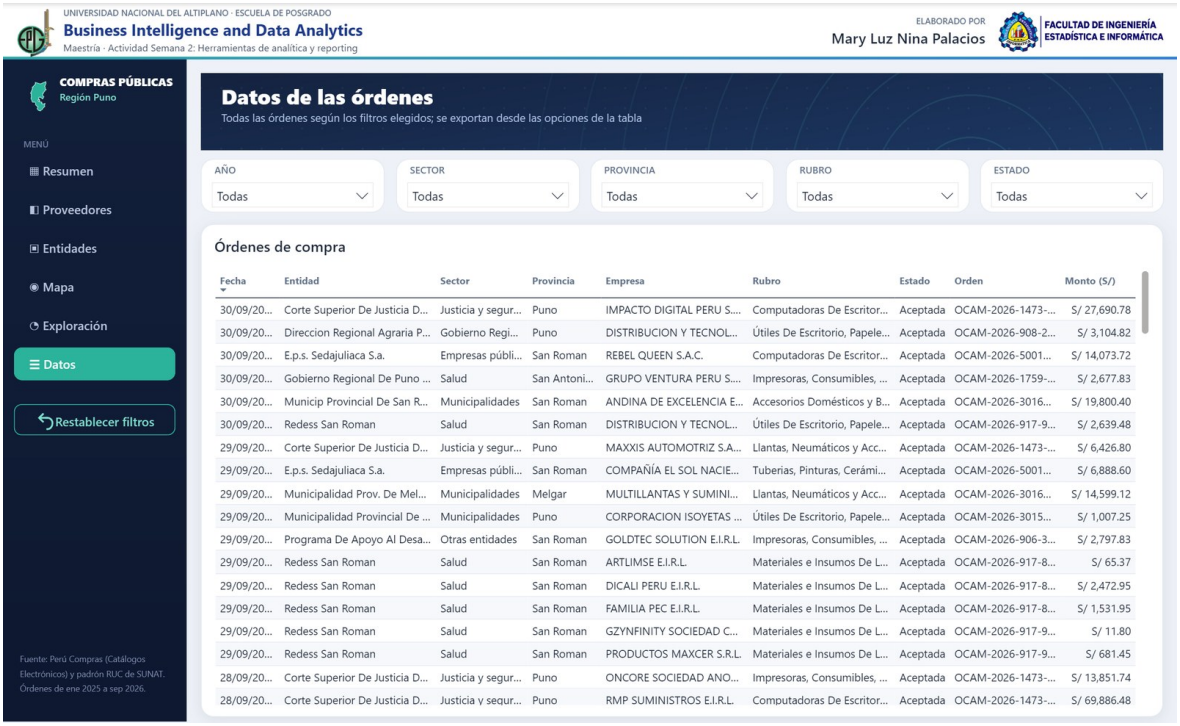


(b) Power BI, página Exploración.

Figura 5: Sección Exploración: estadísticos descriptivos, distribución de los montos, días de emisión y órdenes atípicas.



(a) Shiny, pestaña Datos.



(b) Power BI, página Datos.

Figura 6: Sección Datos: detalle de las órdenes con filtros y exportación.

y S/ 5 mil, pero el 2 % que supera los S/ 100 mil concentra el 39 % del dinero; la orden más grande, de S/ 4,13 millones, fue una compra de computadoras de la Universidad Nacional del Altiplano. Por último, casi la totalidad de las órdenes se emite en días hábiles: entre 1 105 y 1 262 por cada día de lunes a viernes, frente a 69 los sábados y 12 los domingos.

6. Cómo se asignaron los puntajes

6.1 Criterios y escala

La comparación usa doce criterios. Cinco miden la **analítica básica**, es decir, qué tan bien permite cada herramienta preparar, calcular, describir y representar los datos. Los otros siete miden el ***reporting***: cómo se usa, se ve, se publica y se mantiene el reporte. Se eligieron a partir de lo que la literatura señala como esencial en un tablero, que es mostrar lo importante de un vistazo, permitir filtrar y profundizar, y llegar a quien lo necesita (Yigitbasioglu y Velcu, 2012; Sarikaya et al., 2019; Bach et al., 2023), y de la manera en que el análisis visual interactivo apoya la exploración (Heer y Shneiderman, 2012). También se incluyó la reproducibilidad, porque un análisis que no puede repetirse pierde valor como evidencia (Peng, 2011; Sandve et al., 2013).

Para que el puntaje no dependiera de una apreciación general, antes de calificar se fijó qué significa cada nivel de la escala (Tabla 3). Cada criterio se calificó preguntando cómo resolvió la herramienta esa tarea concreta en este proyecto, y el puntaje es el nivel cuya descripción encaja con lo que ocurrió. Todos los criterios pesan lo mismo, así que el subtotal de cada dimensión es la suma de sus puntajes.

Tabla 3: Escala usada para calificar cada criterio

Puntaje	Nivel	Qué tuvo que ocurrir en el proyecto
5	Muy sólido	La herramienta resolvió la tarea de forma nativa o con poco esfuerzo, sin restricciones.
4	Sólido	La resolvió por completo, pero con un esfuerzo adicional moderado (configurar, aprender un concepto nuevo, escribir algo de código).
3	Aceptable	La resolvió solo en parte, mediante un rodeo, o dependiendo de una condición externa como una licencia de pago o el permiso de un administrador.
2	Débil	Solo fue posible con mucho trabajo o con conocimientos especializados previos.
1	Insuficiente	No se pudo resolver en este proyecto.

6.2 Puntajes y evidencia

La Tabla 4 recoge cada puntaje junto con lo que se observó y la figura donde puede verse. A continuación se comentan los criterios con mayor diferencia.

En *estadística descriptiva* Shiny recibe 5 y Power BI 3 porque R entregó el histograma en

escala logarítmica, las densidades por sector y los percentiles sin salir de la aplicación, mientras que en Power BI hubo que sustituir el histograma por rangos de monto y calcular cada estadístico con DAX, lo que corresponde al nivel 3 de la escala (Figura 5). En *cartografía* ocurre lo mismo: Shiny dibujó los 109 distritos con sus límites oficiales, y Power BI solo pudo representar burbujas, además de depender de que Azure Maps esté permitido en la cuenta (Figura 4).

En sentido contrario, Power BI recibe 5 en *interactividad* porque el filtrado cruzado, las ventanas emergentes y el selector de métrica funcionan sin programar. Shiny recibe 4 porque todo eso es posible, pero cada interacción, como el botón de aplicar filtros o el clic sobre el mapa, tuvo que escribirse y probarse. La mayor brecha está en la *curva de aprendizaje*: para una persona que no programa, Power BI produce resultados desde las primeras horas de uso (5), mientras que Shiny exige saber R y entender la programación reactiva (2). Esto coincide con la idea de la inteligencia de negocios de autoservicio, en la que el propio usuario arma sus reportes sin depender de un programador (Alpar y Schulz, 2016), aunque incluso en ese modelo los usuarios enfrentan vacíos de conocimiento cuando el análisis se vuelve más complejo (Lennerholt et al., 2021). En *publicación* y *costo* la situación se invierte. La aplicación Shiny quedó en línea con una cuenta gratuita y un enlace abierto, mientras que compartir un reporte de Power BI con otras personas requiere una cuenta institucional y licencias de pago, por lo que recibe 3 en ambos criterios. En *escalabilidad* Power BI obtiene 5 gracias a su motor en memoria pensado para muchos usuarios, frente a un 3 de Shiny, cuyo plan gratuito suspende la aplicación tras un periodo de inactividad y que, con muchos usuarios a la vez, necesitaría más servidores.

6.3 Cómo leer el resultado

Sumados, Shiny obtiene 53 puntos y Power BI 47, pero esa diferencia proviene íntegramente de la analítica básica. En el *reporting* empatan con 29 puntos, aunque cada una sobresale en criterios distintos: Power BI en interactividad, facilidad de aprendizaje y escalabilidad; Shiny en diseño, publicación, reproducibilidad y costo. Por eso el total no debe leerse como un veredicto general. Si quien mantendrá el reporte no tiene formación en programación, el criterio de curva de aprendizaje adquiere mayor peso y la evaluación se inclina hacia Power BI. Si lo que importa es el análisis estadístico o publicar abiertamente sin costo, favorece a Shiny.

7. Discusión

Los resultados indican que ambas herramientas no compiten en el mismo ámbito. Shiny rinde mejor cuando el análisis es el centro del trabajo: ensayar transformaciones, examinar distribuciones con escalas logarítmicas o marcar los valores atípicos sobre el gráfico. Al ser una interfaz web sobre R, hereda todo lo que el lenguaje ofrece, que es la razón por la que se ha vuelto común para llevar análisis especializados a usuarios sin formación en programación (Jia et al., 2022). Power BI, en cambio, está pensado para la persona que consulta el reporte y necesita filtrar, comparar y obtener una respuesta sin tocar los cálculos, lo que explica que se haya adoptado

Tabla 4: Puntajes por criterio y evidencia que los respalda (escala de la Tabla 3)

Criterio	**Shiny: lo que se observó**	**Pts.**	**Power BI: lo que se observó**	**Pts.**
Analítica básica				
Preparación de datos	Transformaciones en código `dplyr`, documentadas y repetibles.	5	Power Query cubre los pasos simples; la lógica queda repartida en pasos de la interfaz, más difíciles de revisar.	4
Cálculo de indicadores	Cada indicador es una línea de R, pero hay que escribirla para cada salida.	4	Medidas DAX reutilizables en todo el reporte; exigen entender el contexto de filtro.	4
Estadística descriptiva	Histograma logarítmico, densidades, percentiles y asimetría nativos (Fig. 5).	5	Sin histograma ni densidad; se usaron rangos de monto y estadísticos en DAX.	3
Gráficos	`plotly` con anotaciones y control total de cada detalle.	5	Catálogo amplio y pulido, con opciones limitadas por visual.	4
Cartografía	Límites oficiales de 109 distritos y detalle al hacer clic (Fig. 4).	5	Solo burbujas por coordenadas; Azure Maps depende del administrador.	3
Reporting				
Interactividad	Posible, pero cada interacción se programó y probó.	4	Filtrado cruzado, ventana emergente y selector de métrica sin programar.	5
Diseño	Página web con CSS libre: membrete, fondo y tarjetas propias.	5	Lienzo fijo y temas; buen acabado dentro de lo que permite cada visual.	4
Curva de aprendizaje	Requiere R y programación reactiva.	2	Arrastrar y soltar; resultados inmediatos.	5
Publicación	shinyapps.io gratuito y enlace público en minutos.	5	Compartir exige cuenta institucional y licencia de pago.	3
Reproducibilidad	Un archivo de código versionado en GitHub.	5	El formato PBIP permite versionar, aunque es menos legible que un script.	4
Costo	Software libre y plan de publicación gratuito.	5	Desktop gratuito; distribuir el reporte tiene costo por usuario.	3
Escalabilidad	Con muchos usuarios se necesitan más instancias; el plan gratuito se suspende sin uso.	3	Motor columnar en memoria, diseñado para muchos usuarios y registros.	5
Subtotal analítica básica (máximo 25)		**24**		**18**
Subtotal *reporting* (máximo 35)		**29**		**29**
Total (máximo 60)		**53**		**47**

incluso fuera del ámbito empresarial para analizar y visualizar datos diversos (Becker y Gould, 2019). Las comparaciones de Power BI con otras herramientas de visualización también suelen centrarse en la usabilidad y en las funciones de visualización para usuarios de negocio (Sahaya et al., 2024).

Esta diferencia encaja con la distinción entre explorar y comunicar. La exploración requiere libertad para examinar los datos desde varios ángulos (Behrens, 1997), mientras que un buen tablero debe mostrar lo esencial de inmediato y dejar que el usuario profundice cuando lo necesite (Shneiderman, 1996; Yigitbasioglu y Velcu, 2012). En este proyecto el análisis exploratorio resultó más natural en Shiny y el tablero navegable, con filtrado cruzado y ventana emergente, fue más rápido de lograr en Power BI. La interacción, que la literatura considera central en el análisis visual (Heer y Shneiderman, 2012), es justamente lo que Power BI entrega sin costo de desarrollo, mientras que en Shiny hay que construirla.

El acceso es otro factor relevante. Shiny permitió publicar el reporte de forma gratuita y abierta en poco tiempo, algo valioso cuando el propósito es la transparencia y los datos ya son públicos (Janssen et al., 2012). Power BI está concebido para organizaciones con licencias y administradores, y publicar un reporte abiertamente requiere habilitar opciones que muchas instituciones mantienen deshabilitadas. No es un defecto técnico, sino una decisión de diseño orientada a controlar quién ve la información. Por eso, para una oficina de abastecimiento cuyos usuarios necesitan consultas rápidas dentro de la entidad, Power BI sería la opción más práctica, y para un estudio del gasto público que requiera métodos estadísticos más exigentes, Shiny ofrece mayores ventajas.

El estudio presenta algunas limitaciones. Los puntajes reflejan la experiencia de una sola persona con un conjunto de datos de tamaño moderado; aunque la escala se definió de antemano, sigue siendo una valoración y no una medición con usuarios. Tampoco se probaron la actualización automática de datos, la seguridad por filas ni un número elevado de usuarios concurrentes, escenarios en los que Power BI probablemente sumaría ventajas. Finalmente, la región se asignó por el domicilio fiscal de cada entidad, que no siempre coincide con el lugar donde se usa lo comprado.

8. Conclusiones

1. Con los mismos datos se construyeron dos módulos de análisis exploratorio de seis secciones cada uno, una aplicación en Shiny y un reporte en Power BI, y ambos producen exactamente las mismas cifras, lo que hace válida la comparación.

2. En analítica básica Shiny obtuvo más puntos (24 frente a 18), sobre todo en estadística descriptiva, gráficos y cartografía, porque trabaja directamente sobre R.

3. En *reporting* ambas herramientas obtuvieron 29 puntos. Power BI destaca por su interacción sin necesidad de programar, por su facilidad de aprendizaje y por su escalabilidad;

Shiny, por su libertad de diseño, su costo nulo y la posibilidad de publicar abiertamente.

4. Las herramientas se complementan. Un flujo de trabajo recomendable consiste en explorar y validar en R o Shiny y trasladar después los indicadores consolidados a Power BI cuando el reporte deba distribuirse dentro de una organización.

5. Más allá de la comparación, el análisis aporta información relevante para la gestión regional: en 2026 el gasto cayó 22,1 %, se concentra en el distrito de Puno y en el Gobierno Regional, y solo el 12,5 % del monto se adjudica a empresas de la región.

Referencias

Alpar, P. y Schulz, M. (2016). Self-service business intelligence. *Business & Information Systems Engineering, 58*(2), 151–155. https://doi.org/10.1007/s12599-016-0424-6

Bach, B., Freeman, E., Abdul-Rahman, A., Turkay, C., Khan, S., Fan, Y. y Chen, M. (2023). Dashboard design patterns. *IEEE Transactions on Visualization and Computer Graphics, 29*(1), 342–352. https://doi.org/10.1109/TVCG.2022.3209448

Becker, L. T. y Gould, E. M. (2019). Microsoft Power BI: Extending Excel to manipulate, analyze, and visualize diverse data. *Serials Review, 45*(3), 184–188. https://doi.org/10.1080/00987913.2019.1644891

Behrens, J. T. (1997). Principles and procedures of exploratory data analysis. *Psychological Methods, 2*(2), 131–160. https://doi.org/10.1037/1082-989X.2.2.131

Chen, H., Chiang, R. H. L. y Storey, V. C. (2012). Business intelligence and analytics: From big data to big impact. *MIS Quarterly, 36*(4), 1165–1188. https://doi.org/10.2307/41703503

Fazekas, M. y Kocsis, G. (2020). Uncovering high-level corruption: Cross-national objective corruption risk indicators using public procurement data. *British Journal of Political Science, 50*(1), 155–164. https://doi.org/10.1017/S0007123417000461

Heer, J. y Shneiderman, B. (2012). Interactive dynamics for visual analysis. *Communications of the ACM, 55*(4), 45–54. https://doi.org/10.1145/2133806.2133821

Janssen, M., Charalabidis, Y. y Zuiderwijk, A. (2012). Benefits, adoption barriers and myths of open data and open government. *Information Systems Management, 29*(4), 258–268. https://doi.org/10.1080/10580530.2012.716740

Jia, L., Yao, W., Jiang, Y., Li, Y., Wang, Z., Li, H., Huang, F., Li, J., Chen, T. y Zhang, H. (2022). Development of interactive biological web applications with R/Shiny. *Briefings in Bioinformatics, 23*(1), Artículo bbab415. https://doi.org/10.1093/bib/bbab415

Lennerholt, C., van Laere, J. y Söderström, E. (2021). User-related challenges of self-service business intelligence. *Information Systems Management, 38*(4), 309–323. https://doi.org/10.1080/10580530.2020.1814458

Lu, P., Jain, S., León, T. M. y White, L. A. (2026). CalCORVID: A dynamic RShiny dashboard approach to visualize spatiotemporal clusters for public health surveillance. *BMC Public Health, 26*(1), Artículo 925. https://doi.org/10.1186/s12889-026-26201-1

Pebesma, E. (2018). Simple features for R: Standardized support for spatial vector data. *The R Journal, 10*(1), 439–446. https://doi.org/10.32614/RJ-2018-009

Peng, R. D. (2011). Reproducible research in computational science. *Science, 334*(6060), 1226–1227. https://doi.org/10.1126/science.1213847

Sahaya, A. P. N., Purnawarman, D., Rasyidah, F. S., Prabowo, Y. D., Sarwo y Gatc, J. (2024). Powering sales insights: A comparative analysis of data visualization tools, Microsoft Power BI vs Tableau.

En *2024 9th International Conference on Business and Industrial Research (ICBIR)* (pp. 1042–1047). IEEE. https://doi.org/10.1109/ICBIR61386.2024.10875740

Sandve, G. K., Nekrutenko, A., Taylor, J. y Hovig, E. (2013). Ten simple rules for reproducible computational research. *PLoS Computational Biology, 9*(10), Artículo e1003285. https://doi.org/10.1371/journal.pcbi.1003285

Sarikaya, A., Correll, M., Bartram, L., Tory, M. y Fisher, D. (2019). What do we talk about when we talk about dashboards? *IEEE Transactions on Visualization and Computer Graphics, 25*(1), 682–692. https://doi.org/10.1109/TVCG.2018.2864903

Shneiderman, B. (1996). The eyes have it: A task by data type taxonomy for information visualizations. En *Proceedings 1996 IEEE Symposium on Visual Languages* (pp. 336–343). IEEE. https://doi.org/10.1109/VL.1996.545307

Watson, H. J. y Wixom, B. H. (2007). The current state of business intelligence. *Computer, 40*(9), 96–99. https://doi.org/10.1109/MC.2007.331

Yigitbasioglu, O. M. y Velcu, O. (2012). A review of dashboards in performance management: Implications for design and research. *International Journal of Accounting Information Systems, 13*(1), 41–59. https://doi.org/10.1016/j.accinf.2011.08.002

Fuentes de datos

Central de Compras Públicas Perú Compras. (2026). *Órdenes de compra realizadas a través de los Catálogos Electrónicos* [Conjunto de datos]. Plataforma Nacional de Datos Abiertos. https://www.datosabiertos.gob.pe/dataset/órdenes-de-compra-realizadas-través-de-los-catálogos-electrónicos-central-de-compras-públicas-perú-compras

Superintendencia Nacional de Aduanas y de Administración Tributaria. (2026). *Padrón reducido del RUC* [Conjunto de datos]. https://www.sunat.gob.pe/descargaPRR/mrc137_padron_reducido.html